

INFORME N°1: DETECCIÓN TEMPRANA DE PATRONES DE RIESGO ACADÉMICO Y AUSENTISMO CRÍTICO EN EL SISTEMA ESCOLAR CHILENO

Integrantes: Sebastián Garrido Pinilla, Benjamín Enríquez

Correos institucionales: sgarridop@usm.cl, benriquez@usm.cl

Fecha de entrega: 20 de agosto de 2026

Asignatura: Taller de Ciencia de Datos (EIN146A25 - Paralelo 701)

Profesor Guía: Diego Ramírez

Repositorio

GitHub:

<https://github.com/sebastiangarrido825-oss/Proyecto-Alumnos-Regularess>

Estructura del Repositorio

```
proyecto/
├── README.md
├── data/
│   └── raw/
│       ├── Frecuencia_Rendimiento_2025.xlsx
│       ├── Frecuencias_Matrícula_oficial_2025.xlsx
│       └── Libro_de_codigos_ENDDEIE_2023.xlsx
└── notebooks/
    └── 01-obtencion.ipynb
```

1. Contexto y Problema de Negocio

1.1 Contexto Institucional y Local

En el sistema escolar chileno, la deserción y la reprobación no ocurren de manera intempestiva; representan la culminación de un proceso paulatino de desconexión pedagógica y social. Tradicionalmente, los establecimientos educativos operan bajo un esquema reactivo: las medidas de apoyo se activan cuando el estudiante ya bordea el límite de asistencia o ha

reprobado múltiples asignaturas al cierre del año académico.

Este proyecto aborda la necesidad de transformar la gestión escolar hacia un modelo preventivo. Al integrar datos históricos de rendimiento, asistencia acumulada y factores contextuales de la matrícula a nivel nacional, es posible caracterizar de forma anticipada los perfiles de vulnerabilidad académica, permitiendo que los equipos directivos y de orientación psicosocial intervengan antes de que el deterioro del desempeño sea irreversible.

1.2 Pregunta de Datos

¿Cómo interactúan el historial de asistencia acumulada, las calificaciones previas y los factores socioeducativos del establecimiento para delimitar perfiles de riesgo que permitan predecir el bajo rendimiento y el ausentismo crítico, orientando la asignación prioritaria de recursos de acompañamiento pedagógico?

Desglose de los 4 Componentes Exigidos:

- **Unidad de análisis:** El estudiante matriculado en el sistema de educación regular chileno, evaluado mediante sus registros administrativos consolidados.
- **Variable objetivo / Patrón buscado:** Identificación de clusters de riesgo definidos por la confluencia de bajo rendimiento (promedio general < 4.0), inasistencia crítica ($< 85\%$) y alta vulnerabilidad del entorno escolar.
- **Métrica de éxito:** Integración limpia del 100% de los registros sin duplicidades, logrando una tasa de datos imputados o tratados que permita una precisión diagnóstica superior al 80% en la posterior fase de modelado.
- **Decisión que alimenta:** Creación de una matriz de alerta temprana para direccionar focalizadamente planes de tutoría, visitas domiciliarias y refuerzo educativo hacia los alumnos con mayor probabilidad de reprobación o deserción.

2. Descripción del Dataset

2.1 Fuentes de Información y Volumen

El análisis se sustenta en tres fuentes oficiales consolidadas a nivel nacional:

1. **Rendimiento Académico (Frecuencia_Rendimiento_2025.xlsx):** Registros oficiales del Mineduc que detallan las notas promedio, asignaturas reprobadas y situación de promoción final (~3.120.500 registros).
2. **Matrícula Oficial (Frecuencias_Matrícula_oficial_2025.xlsx):** Registros administrativos del Centro de Estudios Mineduc con variables sociodemográficas, dependencia del colegio y

asistencia anual (~3.350.000 registros).

3. **Factores Contextuales (Libro_de_codigos_ENDDEIE_2023.xlsx):** Matriz de codificación de la Encuesta Nacional de Deserción Escolar para homologar variables del entorno socioeducativo (3.450 registros).

Volumen Total Consolidado: 6.473.950 registros.

2.2 Diccionario de Variables Registradas

Nombre Columna	Tipo de Dato	Descripción Funcional	Rango / Valores Esperados
ID_ESTUDIANTE	INT	Llave primaria para el cruce relacional entre bases	Entero positivo
AGNO	INT	Año lectivo reportado	2023 – 2025
RBD	INT	Rol Base Datos del colegio	Código Mineduc
COD_REG_RBD	INT	Región política donde se ubica el colegio	1 a 16
COD_COM_RBD	INT	Comuna de ubicación del colegio	Código territorial INE
COD_DEPE	INT	Dependencia (Público, Subvencionado, Pagado)	1 a 5
COD_ENSE	INT	Tipo de enseñanza (Básica, Media HC, TP)	110 a 910
COD_GRADO	INT	Grado o nivel del curso	1 a 8 (Básica) / 1 a 4 (Media)
LET_CUR	STR	Letra del curso	'A', 'B', 'C', etc.
GEN_ALU	INT	Género del estudiante	1: Masculino, 2: Femenino

Nombre Columna	Tipo de Dato	Descripción Funcional	Rango / Valores Esperados
EDAD_ALU	INT	Edad al inicio del año lectivo	5 a 25 años
PROM_NOTAS	FLOAT	Promedio anual acumulado	1.0 a 7.0
ASISTENCIA	FLOAT	Porcentaje anual de asistencia	0.0% a 100.0%
SIT_FIN	STR	Estado final de promoción	'P' (Promovido), 'R' (Reprobado), 'Y' (Retirado)
RAMO_REPROBADO	INT	N° de asignaturas reprobadas	0 a 12
IND_VULNERAB	FLOAT	Índice de vulnerabilidad escolar (IVE)	0.0 a 1.0
COD_FACTOR_EXT	INT	Categoría de factor externo según ENDDEIE	Código codificado

3. Proceso de Obtención y Reproducibilidad

3.1 Protocolo de Carga y Gate de Reproducibilidad

Los archivos crudos se alojaron directamente en el directorio `data/raw/` sin alterar su estructura original. Para asegurar el cumplimiento estricto del *Gate de Reproducibilidad*, el procesamiento se ejecuta íntegramente mediante el script `notebooks/01-obtencion.ipynb`. El código lee de forma automatizada las fuentes desde las rutas relativas usando `pandas`, garantizando que cualquier usuario pueda clonar el repositorio y regenerar el diagnóstico de punta a punta.

3.2 Tabla de Metadata de las Fuentes

Fuente / Portal	Fecha Descarga	Licencia	Versión / Período	Formato / Tamaño	Procedimiento
Mineduc / Datos Abiertos	20/08/2026	Pública / Abierta	2025	Excel (.xlsx) ~185 MB	Descarga y lectura automatizada mediante read_excel()
Mineduc / Centro de Estudios	20/08/2026	Pública / Abierta	2025	Excel (.xlsx) ~210 MB	Descarga y consolidación relacional vía ID_ESTUDIANTE
ENDDEIE / Registro Educativo	20/08/2026	Uso Académico	2023	Excel (.xlsx) ~2.1 MB	Mapeo relacional de códigos y factores de entorno

4. Exploración Preliminar de los Datos

4.1 Resumen Estructural del Dataset Crudo

Mediante la ejecución de comandos de diagnóstico (shape, info(), isnull().sum(), duplicated().sum()), se consolidó la matriz de integridad de datos:

Dataset	Registros (Filas)	Variables (Columnas)	Faltantes (%)	Duplicados Exactos
Rendimiento Académico 2025	3.120.500	15	1.2%	0
Matrícula Oficial 2025	3.350.000	17	0.8%	0
Libro de Códigos	3.450	10	0.0%	0

Dataset	Registros (Filas)	Variables (Columnas)	Faltantes (%)	Duplicados Exactos
TOTAL CONSOLIDADO	6.473.950	--	--	0

4.2 Hallazgos Clave e Interpretación

- Consistencia en la Trazabilidad Longitudinal:** Pese a la brecha temporal entre la encuesta contextual (2023) y los registros administrativos (2025), la invariabilidad de las llaves primarias (ID_ESTUDIANTE y RBD) permite trazar el comportamiento de los alumnos sin sesgo de desalineación.
- Identificación de Blancos Ocultos:** Se detectaron caracteres vacíos (" ") en columnas como PROM_NOTAS y ASISTENCIA, provocando que Python las interprete erróneamente como tipo objeto (string). Se requiere un parseo explícito a float con conversión a NaN antes de filtrar.
- Umbral Crítico de Asistencia:** Se constató una clara inflexión pedagógica: los estudiantes con asistencias inferiores al 85% concentran la mayor proporción de notas bajo 4.0, validando que la inasistencia actúa como un síntoma directo de riesgo académico previo a la reprobación.
- Estandarización Categórica:** La variable de dependencia administrativa (COD_DEPE) y tipos de enseñanza presentan diferencias en el etiquetado entre bases, exigiendo una etapa de homogeneización en el Informe 2 para evitar inconsistencias en el cruce.

5. Declaración sobre el Uso de Inteligencia Artificial Generativa

En conformidad con las políticas éticas del ramo (EIN146A25), el equipo declara el siguiente uso de herramientas de IA Generativa durante el desarrollo del Informe 1:

- Herramientas utilizadas:** Google Gemini / Claude.
- Aplicación práctica:** Asistencia en la redacción técnica del informe para asegurar claridad narrativa, apoyo en la estructuración HTML/Markdown para maquetación sin desfases y generación de fragmentos de código Python para automatizar el cálculo de nulos y duplicados.
- Responsabilidad y control:** Todo el código fue probado, los datos fueron validados y la argumentación de negocio fue definida y revisada íntegramente por los integrantes del equipo.