

Informe 2: Preprocesamiento de Datos y Feature Engineering

Equipo: Sebastián garrido

Benjamín Enríquez

Correos:

Sgarridop@usm.cl

benriquez@usm.cl

Fecha: 21/09/2026

Profesor: Diego Ramírez

Declaración de Uso de Inteligencia Artificial

Declaración: AFIRMATIVA

Detalle: Se utilizó IA (Gemini) y Claude como apoyo para la corrección de errores en código Python y la redacción del documento. El análisis y las conclusiones son de responsabilidad del autor.

1. Metodología de Carga y Consolidación

Para garantizar la reproducibilidad y trazabilidad, la integración de las bases de datos de Matrícula y Rendimiento del MINEDUC se realizó mediante un script en Python (celdas [1] a [3]). Se utilizó la librería `glob` para la lectura de múltiples archivos CSV, unificando los identificadores de los estudiantes mediante la variable `id_estudiante` (MRUN). La concatenación de registros se realizó asegurando la consistencia de los tipos de datos y evitando duplicados estructurales.

2. C4: Características Nuevas (Feature Engineering)

Se construyeron tres variables derivadas clave para enriquecer el análisis predictivo de riesgo académico:

- **Escalamiento/Normalización (prom_notas_norm):** Se homogeneizó la escala de notas dividiendo por \$10.0\$ los valores superiores a \$10\$ (celda [3]), dejando todas las calificaciones en el rango continuo \$[1.0, 7.0]\$.
- **Estandarización Z-Score (prom_notas_norm_std):** Se calculó el puntaje Z de cada estudiante respecto al promedio poblacional (μ) y desviación estándar (σ) (celda [18]). Esto permite identificar estudiantes atípicos en el extremo inferior ($Z < -2$).
- **Indicadores de Riesgo y Reprobación (riesgo_academico y estudiante_reprobado):** Se crearon variables binarias (\$0\$ o \$1\$) para catalogar automáticamente a estudiantes con nota inferior a \$4.0\$ o con situación final de reprobación (SIT_FIN $\in \{\text{'R'}, \text{'Y'}, \text{'2'}, \text{'3'}\}$).

3. Resultados Clave del Análisis

- **Valores Atípicos / Extremos:** Un **2.1%** de la matrícula presenta calificaciones fuertemente rezagadas ($Z < -2$), concentrando el mayor riesgo de deserción (celda [18]).
- **Brechas por Situación Final y Género:** La variable estandarizada prom_notas_norm_std muestra diferencias marcadas entre alumnos promovidos y reprobados, así como variaciones según género y año académico, validando la utilidad pedagógica y predictiva de las nuevas métricas (celda [18]).